

MIYAGI

Auditoria crítica e independente

Estratégia de time-series momentum multiativo - Desafio Quant AI 2026

Veredito. A estratégia continua positiva e passa os seis critérios de robustez declarados. Porém, o Sharpe auditado é **0,47**, não 0,50, e a evidência estatística é marginal. O histórico não pode ser chamado integralmente fora da amostra, e o painel mistura instrumentos com economias incompatíveis. Este é um proxy acadêmico de pesquisa, não ainda um retorno implementável.

Resumo quantitativo

Versão	CAGR	Vol.	Sharpe	Max DD
Relatório anterior	15,9%	10,5%	0,50	-23,0%
Motor auditado	15,6%	10,5%	0,47	-24,1%
Seleção anual defasada, 2016-2026	12,9%	10,6%	0,34	-25,0%

O que mudou no motor: retorno calculado com `fill_method=None`; painel corrigido usado em todos os scripts; pesos efetivos derivam entre rebalanceamentos; contribuição usa o peso anterior ao retorno; lacunas e exposição sem retorno são registradas.

Achados prioritários

- CRÍTICO** **Linhagem inconsistente.** Robustez e figuras usavam `pool_expandido.csv`, enquanto o resultado final usava `pool_carrego.csv`. A carteira publicada mostrava TRY comprada; o motor corrigido a coloca vendida em -0,614.
- CRÍTICO** **Seleção com informação futura.** Elegibilidade, correlações e medoides foram calculados até 2026 e aplicados desde 2005. A regra de 15 anos nem poderia ser executada em 2005 sobre um pool iniciado em 2000.
- CRÍTICO** **Dados ausentes dependiam da versão do pandas.** O padrão antigo de `pct_change()` preenchia buracos e criava saltos de reabertura. A opção explícita sem preenchimento reproduzia o 0,50 documentado, mas ainda deixava posições ativas durante lacunas.
- ALTO** **Economia dos instrumentos.** O painel soma CDI a ETFs, índices de preço, futuros contínuos e FX. Essa soma só é correta se todas as pernas arriscadas forem retornos excedentes financiados, o que não ocorre.
- ALTO** **Inferência frágil.** Autocorrelação, caudas e o caminho de pesquisa tornam $t=2,19$ insuficiente para uma alegação forte de significância.

1. Modelagem e execução

1.1 Rebalanceamento mensal versus diário implícito

O código anterior aplicava o mesmo vetor de pesos todos os dias do mês. Isso equivale a restaurar diariamente os pesos-alvo, sem cobrar as negociações dessa restauração. O motor auditado mantém quantidades/notionais entre datas mensais e deixa os pesos derivarem com preços e patrimônio. A mudança reduz o Sharpe de 0,50 para 0,47 e aumenta o drawdown de -23,0% para -24,1%.

1.2 Atribuição temporal

O relatório atribuía o retorno do dia de rebalanceamento à carteira nova. A estratégia declara que decide no fechamento e só colhe retornos a partir do dia seguinte. O novo log `pesos_diarios` registra a exposição efetiva antes de cada retorno. TRY continua sendo a maior contribuição, agora cerca de +1,16% ao ano, mas a última posição correta é vendida.

1.3 Lacunas

Foram identificadas **60 lacunas internas maiores que cinco dias**. Em **330 de 5.386 dias** de carregamento (6,1%) havia posição ativa e ao menos um retorno ausente. A exposição absoluta média nesses dias foi 6,5%; o máximo, 44,2%. O motor mantém P&L zero onde não há retorno e registra a exposição, mas isso é uma convenção de diagnóstico, não uma cotação observada.

Decisão correta: não interpolar preços nem inventar retornos. Para uma versão implementável, cada lacuna precisa ser resolvida na fonte ou levar a uma regra de saída/tradabilidade definida antes do teste.

1.4 Instrumentos

Tipo no universo	N	Problema econômico
Futuros contínuos Yahoo	15	roll e custo de rolagem não identificados
ETFs adjusted close	11	retorno total financiado, não excesso de futuro
FX com carry proxy	6	taxas proxy; sem vintage e lag de publicação
FX spot	4	carry ausente
Índices de preço	4	dividendos e conversão cambial ausentes

Adicionar CDI integralmente é defensável para uma carteira de futuros com collateral, desde que cada série arriscada seja um retorno excedente de contrato. Não é defensável de forma uniforme para o painel atual. Também faltam roll, borrow de posições vendidas, margem, haircuts e custos específicos.

2. Viés de seleção

2.1 O vazamento

O funil é cego a retorno médio, mas não ao futuro. Um ativo só entra se, visto em 2026, tiver 15 anos de histórico; a correlação e o representante do cluster são escolhidos sobre toda a amostra. Saber antecipadamente quais ativos sobreviverão e como se correlacionarão é informação futura.

2.2 Teste anual defasado

Foi implementada uma seleção no último dia disponível de cada ano, usada apenas no ano seguinte. Mantém-se a regra declarada de 15 anos, sem encurtá-la para obter um resultado melhor. Por isso o primeiro corte possível é dezembro de 2015 e o primeiro retorno é de 2016.

Período	CAGR	Vol.	Sharpe	Max DD
2016-2026, seleção anual defasada	12,9%	10,6%	0,34	-25,0%

O número é positivo, mas não é comparável diretamente ao Sharpe 0,47 de 2005-2026. Ele responde a uma pergunta mais restrita: quanto resta quando o funil explícito só usa o passado, no período em que o requisito é possível.

Rótulo obrigatório: pseudo-point-in-time. Os CSVs atuais foram baixados retrospectivamente. Sem snapshots/vintages do Yahoo e ALFRED não se prova que o provedor mostrava exatamente esses valores e esse conjunto de ativos em cada data histórica.

2.3 Pré-registro

O commit 88392ef registrou Sharpe 0,65 para o walk-forward de 40 ativos. O realizado daquela etapa foi 0,48, fora da banda de $\pm 0,10$. Logo, a previsão original falhou. Recalcular depois a fórmula com Sharpe 0,36 e 11,2 apostas para obter 0,455, comparando com a amostra completa, é uma checagem pós-hoc de consistência, não confirmação independente.

3. Inferência estatística

Estimador	Lag	t	p bilateral
Diário IID	0	2,189	0,0286
Diário Newey-West	21	1,908	0,0564
Diário Newey-West	252	1,936	0,0529
Mensal IID	0	1,988	0,0468
Mensal Newey-West	24	1,913	0,0557

4. Múltiplos testes e incerteza

O p bilateral IID é 0,0286. Bonferroni para apenas quatro combinações dá **0,114**; no teste unilateral, 0,057. Quatro subestima o caminho total, que inclui universos, estimadores, horizontes, janelas, alavancagem, expansão e mudanças de modelo. Portanto nem esse ajuste deve ser apresentado como conservador completo.

Bloco bootstrap	IC 2,5%	Mediana	IC 97,5%
21 dias	-0,037	0,466	0,947
63 dias	0,025	0,470	0,960
252 dias	0,002	0,486	0,960

Os três blocos foram declarados e reportados conjuntamente; nenhum foi selecionado por favorecer a estratégia. O limite inferior muda de sinal, o que reforça a leitura de evidência marginal. Um passo adicional adequado é White Reality Check/SPA ou Deflated Sharpe Ratio sobre o conjunto completo de estratégias realmente tentadas, cuja contagem precisa ser reconstruída do log.

5. Robustez após as correções

Teste	Resultado auditado	Veredito
Custos	0,2%/trade: CAGR 14,3%	PASSA
Janela de vol	Sharpe mínimo 0,40	PASSA
Subperíodos	supera CDI em 3 de 4	PASSA
Alavancagem	teto 2x: CAGR 14,1%	PASSA
Jackknife por classe	pior Sharpe 0,41, sem câmbio	PASSA
Horizonte	Sharpe positivo em 4 de 4	PASSA

Isso permite dizer: o resultado não depende de uma única escolha entre as seis variações testadas. Não permite dizer: o resultado está livre de erro de modelagem, seleção ou múltiplos testes. O erro de carry original já havia passado por testes de robustez, mostrando por que robustez paramétrica e validade econômica são perguntas diferentes.

6. Controle de risco

O teto de 3x é atingido em **48,3%** dos rebalanceamentos, não cerca de 23%. Logo, ele é parte ativa do perfil de retorno e risco, embora o teste com 2x continue superando o CDI. A volatilidade agregada de 10,5% próxima ao alvo de 10% não valida sozinha a previsão mensal de risco nem a matriz 40x40 estimada com apenas 60 dias.

7. O que pode ser afirmado

Afirmção sustentada	Afirmção que deve ser removida
A estratégia tem retorno excedente positivo na amostra.	"Sharpe 0,50 é estatisticamente robusto."
Os seis critérios declarados sobrevivem ao motor auditado.	"2005-2026 é todo fora da amostra."
O funil anual causal mantém Sharpe positivo em 2016-2026.	"A previsão de diversificação foi confirmada."
TRY continua relevante após a correção de carry.	"A queda da duração das tendências causou o bloco ruim."
O painel serve a uma prova acadêmica transparente.	"O backtest representa execução real de futuros."

8. Ordem de correção recomendada

1. Usar uma única fonte oficial em código, gráficos, robustez e carteira.
2. Fixar versões, retorno sem preenchimento e auditoria de lacunas.
3. Manter timing causal e deriva de pesos entre rebalanceamentos.
4. Rotular o funil completo como in-sample e reportar o teste anual 2016+.
5. Reescrever significância e pré-registro com HAC e múltiplos testes.
6. Reconstruir instrumentos: contratos e rolls de futuros; forwards de FX; índices total return ou futuros de ações; funding e collateral consistentes.

Artefatos reproduzíveis

- dados_miyagi.py: fonte única e regras de calendário.
- auditoria_dados.py: lacunas, exposição sem retorno e tipos.
- auditoria_estatistica.py: IID, HAC, Bonferroni e bootstrap.
- auditoria_selecao.py: funil anual defasado.
- robustez.py --universo 40: seis testes no painel oficial.
- tests/test_backtest.py: testes contra preenchimento implícito, sinal sem cotação e divergência de painel.

Conclusão final. O projeto tem mérito por registrar erros e manter parâmetros mesmo quando alternativas parecem melhores. A contribuição mais forte para o desafio não é vender um Sharpe de 0,50 como fato; é mostrar uma pesquisa que encontrou onde o próprio número falhava, corrigiu o motor e preservou as limitações sem fabricar dados.

Fontes metodológicas principais

Moskowitz, Ooi e Pedersen (2012), Time Series Momentum; Hurst, Ooi e Pedersen (2017), A Century of Evidence on Trend-Following; White (2000), A Reality Check for Data Snooping; Bailey e López de Prado (2014), The Deflated Sharpe Ratio. Resultados numéricos desta auditoria foram produzidos exclusivamente pelos CSVs versionados no repositório.