

MIYAGI

Auditoria crítica e independente

Estratégia de time-series momentum multiativo - Desafio Quant AI 2026

Veredito. O overlay histórico tem Sharpe **0,48**, mas soma CDI a 11 ETFs cujo adjusted close já é retorno total. Ao financiar somente essas pernas a CDI, o Sharpe cai para **0,13** e apenas três dos seis critérios de robustez passam. O histórico não é integralmente fora da amostra e o painel mistura economias incompatíveis. Este é um proxy acadêmico, não retorno implementável. Como os retornos permanecem nas moedas de origem, 0,13 é um stress contábil sob o numerário do projeto, não uma carteira em reais.

Resumo quantitativo

Versão	CAGR	Vol.	Sharpe	Max DD
Relatório anterior	15,9%	10,5%	0,50	-23,0%
Overlay após auditoria do motor	15,7%	10,5%	0,48	-24,0%
11 ETFs financiados a CDI	11,5%	10,5%	0,13	-25,8%
Seleção anual 2016-2026, ETFs financiados	9,7%	10,6%	0,06	-28,5%

O que mudou no motor: retorno calculado com `fill_method=None`; painel com proxy de carry usado em todos os scripts; pesos efetivos derivam entre rebalanceamentos; contribuição usa o peso anterior ao retorno; a idade da cotação é limitada uma única vez; lacunas e exposição sem retorno são registradas.

Achados prioritários

- CRÍTICO** **Linhagem inconsistente.** Robustez e figuras usavam `pool_expandido.csv`, enquanto o resultado final usava `pool_carrego.csv`. A carteira publicada mostrava TRY comprada; o motor corrigido a coloca vendida em -0,614.
- CRÍTICO** **Seleção com informação futura.** Elegibilidade, correlações e medoides foram calculados até 2026 e aplicados desde 2005. A regra de 15 anos nem poderia ser executada em 2005 sobre um pool iniciado em 2000.
- CRÍTICO** **Dados ausentes dependiam da versão do pandas.** O padrão antigo de `pct_change()` preenchia buracos e criava saltos de reabertura. A opção explícita sem preenchimento reproduzia o 0,50 documentado, mas ainda deixava posições ativas durante lacunas.
- CRÍTICO** **Financiamento dos ETFs.** O painel soma CDI a ETFs, índices, futuros e FX. Nos 11 ETFs, cobrar CDI da exposição líquida reduz o Sharpe de 0,48 para 0,13; o encargo médio medido é 3,65 p.p. ao ano.
- ALTO** **Inferência frágil.** Autocorrelação, caudas e o caminho de pesquisa tornam $t=2,20$ insuficiente para uma alegação forte de significância.

1. Modelagem e execução

1.1 Rebalanceamento mensal versus diário implícito

O código anterior aplicava o mesmo vetor de pesos todos os dias do mês. Isso equivale a restaurar diariamente os pesos-alvo, sem cobrar as negociações dessa restauração. O motor auditado mantém quantidades/notionais entre datas mensais e deixa os pesos derivarem com preços e patrimônio. O conjunto das correções do motor muda o Sharpe de 0,50 para 0,48 e o drawdown de -23,0% para -24,0%; não se atribui toda a diferença à deriva sem contrafactual isolado. Testes novos verificam a fórmula analítica, o giro seguinte e a interrupção quando o patrimônio fica não positivo.

1.2 Atribuição temporal

O relatório atribuía o retorno do dia de rebalanceamento à carteira nova. A estratégia declara que decide no fechamento e só colhe retornos a partir do dia seguinte. O novo log `pesos_diarios` registra a exposição efetiva antes de cada retorno. TRY continua sendo a maior contribuição, agora cerca de +1,16% ao ano, mas a última posição correta é vendida.

1.3 Lacunas

Depois do preenchimento máximo permitido, restam **52 lacunas internas** no calendário oficial. Em **489 de 5.387 observações diárias** (9,1%) havia posição ativa e ao menos um retorno ausente. A exposição absoluta média nesses dias foi 6,8%; o máximo, 45,23% no overlay e 45,25% no stress financiado. O motor mantém P&L zero onde não há retorno e registra a exposição, mas isso é uma convenção de diagnóstico, não uma cotação observada.

O alinhamento anterior aplicava `ffill(limit=5)` duas vezes; valores já imputados renovavam a própria idade e podiam atravessar até dez datas. O novo teste garante que o limite conta desde a última cotação realmente observada.

Decisão correta: não interpolar preços nem inventar retornos. Para uma versão implementável, cada lacuna precisa ser resolvida na fonte ou levar a uma regra de saída/tradabilidade definida antes do teste.

1.4 Instrumentos

Tipo no universo	N	Problema econômico
Futuros contínuos Yahoo	15	roll e custo de rolagem não identificados
ETFs adjusted close	11	retorno total financiado, não excesso de futuro
FX com carry proxy	6	taxas proxy; sem vintage e lag de publicação
FX spot	4	carry ausente
Índices de preço	4	dividendos e conversão cambial ausentes

Adicionar CDI integralmente é defensável para uma carteira de futuros com collateral, desde que cada série arriscada seja um retorno excedente de contrato. Não é defensável de forma uniforme para o painel atual. Também faltam roll, borrow de posições vendidas, margem, haircuts e custos específicos.

Convenção, universo fixo	CAGR	Vol.	Sharpe	Max DD
Overlay histórico	15,7%	10,5%	0,48	-24,0%
11 ETFs financiados a CDI	11,5%	10,5%	0,13	-25,8%
ETFs + índices financiados, stress	10,0%	10,5%	-0,01	-26,9%

A exposição líquida média aos ETFs é 34,5% do patrimônio; a bruta, 74,5%. É a exposição líquida assinada, não os 2,5x brutos do portfólio, que determina o encargo nesta convenção. O stress com índices não é correção completa porque dividendos, FX e instrumento negociável continuam ausentes. O stress com ETFs tampouco resolve a conversão cambial: cobra CDI de retornos que continuam denominados nas moedas de origem. Deslocar o carry em 21 pregões muda o Sharpe do overlay de 0,476 para 0,466; isso mede sensibilidade, mas não cria vintages.

2. Viés de seleção

2.1 O vazamento

O funil é cego a retorno médio, mas não ao futuro. Um ativo só entra se, visto em 2026, tiver 15 anos de histórico; a correlação e o representante do cluster são escolhidos sobre toda a amostra. Saber antecipadamente quais ativos sobreviverão e como se correlacionarão é informação futura.

2.2 Teste anual defasado

Foi implementada uma seleção no último dia disponível de cada ano, usada apenas no ano seguinte. Mantém-se a regra declarada de 15 anos, sem encurtá-la para obter um resultado melhor. Por isso o primeiro corte possível é dezembro de 2015 e o primeiro retorno é de 2016.

Período	CAGR	Vol.	Sharpe	Max DD
2016-2026, overlay	12,9%	10,5%	0,34	-25,0%
2016-2026, ETFs financiados	9,7%	10,6%	0,06	-28,5%

Os números não são comparáveis diretamente aos de 2005-2026. Eles respondem a uma pergunta mais restrita: quanto resta quando o funil explícito só usa o passado, no período em que o requisito é possível.

Rótulo obrigatório: pseudo-point-in-time. Os CSVs atuais foram baixados retrospectivamente. Sem snapshots/vintages do Yahoo e ALFRED não se prova que o provedor mostrava exatamente esses valores e esse conjunto de ativos em cada data histórica.

2.3 Pré-registro

O commit 88392ef registrou Sharpe 0,65 para o walk-forward de 40 ativos. O realizado daquela etapa foi 0,48, fora da banda de $\pm 0,10$. Logo, a previsão original falhou. Recalcular depois a fórmula com Sharpe 0,36 e 11,2 apostas para obter 0,455, comparando com a amostra completa, é uma checagem pós-hoc de consistência, não confirmação independente.

3. Inferência estatística

Overlay histórico:

Estimador	Lag	t	p bilateral
Diário IID	0	2,199	0,0279
Diário Newey-West	21	1,915	0,0555
Diário Newey-West	252	1,944	0,0519
Mensal IID	0	1,996	0,0459
Mensal Newey-West	24	1,921	0,0548

Com os ETFs financiados, o Sharpe é 0,127, t IID 0,586 e p bilateral 0,558. Os t HAC diários ficam entre 0,515 e 0,578; o IC bootstrap de 95% contém zero com folga em todos os blocos (por exemplo, [-0,369; 0,586] em 21 dias). Não há evidência estatística de retorno excedente nesse cenário.

4. Múltiplos testes e incerteza

O p bilateral IID é 0,0279. Bonferroni para apenas quatro combinações dá **0,112**; no teste unilateral, 0,056. Quatro subestima o caminho total, que inclui universos, estimadores, horizontes, janelas, alavancagem, expansão e mudanças de modelo. Portanto nem esse ajuste deve ser apresentado como conservador completo.

Bloco bootstrap	IC 2,5%	Mediana	IC 97,5%
21 dias	-0,037	0,467	0,950
63 dias	0,024	0,473	0,964
252 dias	0,004	0,489	0,960

Os três blocos foram declarados e reportados conjuntamente; nenhum foi selecionado por favorecer a estratégia. O limite inferior muda de sinal, o que reforça a leitura de evidência marginal. Um passo adicional adequado é White Reality Check/SPA ou Deflated Sharpe Ratio sobre o conjunto completo de estratégias realmente tentadas, cuja contagem precisa ser reconstruída do log.

5. Robustez condicionada ao financiamento

Teste	Critério	Overlay	ETFs financiados
Custos	supera CDI a 0,2%/trade	PASSA	FALHA
Janela de vol	Sharpe mínimo 0,25	PASSA	FALHA
Subperíodos	supera CDI em 3 de 4	PASSA	PASSA
Alavancagem	teto 2x supera CDI	PASSA	PASSA
Jackknife classe	Sharpe mínimo 0,25	PASSA	FALHA
Horizonte	positivo em 3 de 4	PASSA	PASSA

O enunciado “6 de 6” vale apenas sob a contabilidade homogênea de overlay. No cenário financiado são **3 de 6**; o dobro do custo produz CAGR 10,2%, a janela pior tem Sharpe 0,07 e retirar câmbio leva o Sharpe a 0,00. Robustez paramétrica não compensa erro econômico de instrumento.

6. Controle de risco

O teto de 3x é atingido em **48,6%** dos rebalanceamentos, não cerca de 23%. Logo, ele é parte ativa do perfil de retorno e risco, embora o teste com 2x continue superando o CDI. A volatilidade agregada de 10,5% próxima ao alvo de 10% não valida sozinha a previsão mensal de risco nem a matriz 40x40 estimada com apenas 60 dias.

7. O que pode ser afirmado

Afirmção sustentada	Afirmção que deve ser removida
A estratégia tem retorno excedente positivo no proxy de overlay.	"Sharpe 0,48 é estatisticamente robusto."
Três critérios sobrevivem com ETFs financiados.	"2005-2026 é todo fora da amostra."
O funil anual mantém Sharpe 0,06 no cenário financiado.	"A previsão de diversificação foi confirmada."
TRY continua relevante após a correção de carry.	"A queda da duração das tendências causou o bloco ruim."
O painel serve a uma prova acadêmica transparente.	"O backtest representa execução real de futuros."

8. Ordem de correção recomendada

1. Usar uma única fonte oficial em código, gráficos, robustez e carteira.
2. Fixar versões, retorno sem preenchimento e auditoria de lacunas.
3. Manter timing causal, deriva testada e interrupção explícita na insolvência.
4. Quantificar financiamento por tipo; não apresentar 0,48 como implementável.
5. Rotular o funil completo como in-sample e reportar o teste anual 2016+.
6. Reescrever significância e pré-registro com HAC e múltiplos testes.
7. Reconstruir instrumentos: contratos e rolls de futuros; forwards de FX; índices total return ou futuros de ações; funding e collateral consistentes.

Artefatos reproduzíveis

- dados_miyagi.py: fonte única e regras de calendário.
- auditoria_dados.py: lacunas, exposição sem retorno e tipos.
- auditoria_financiamento.py: CDI e pernas financiadas.
- auditoria_lag_carrego.py: stress de 21 pregões no carry.
- auditoria_estatistica.py: IID, HAC, Bonferroni e bootstrap.
- auditoria_selecao.py: funil anual defasado.
- robustez.py --universo 40: seis testes no painel oficial.
- tests/test_backtest.py: calendário, preenchimento, sinal, deriva, giro, financiamento, insolvência e linhagem.

Conclusão final. O projeto tem mérito por registrar erros e manter parâmetros mesmo quando alternativas parecem melhores. A contribuição mais forte para o desafio não é vender um Sharpe de 0,48 como fato implementável; é mostrar uma pesquisa que mediu que o cenário financiado cai a 0,13, preservou as limitações e não fabricou dados para recuperar desempenho.

Fontes metodológicas principais

Moskowitz, Ooi e Pedersen (2012), Time Series Momentum; Hurst, Ooi e Pedersen (2017), A Century of Evidence on Trend-Following; White (2000), A Reality Check for Data Snooping; Bailey e López de Prado (2014), The Deflated Sharpe Ratio. Resultados numéricos desta auditoria foram produzidos exclusivamente pelos CSVs versionados no repositório.